

CIENCIA DE DATOS

TRABAJO PRÁCTICO N° 3

CLASIFICANDO DE POBRES EN LA EPH

Fecha de entrega: 31 de octubre a las 23:59 hs.

Contenido: Comenzar con la aplicación de los métodos de clasificación vistos en clase.

Modalidad de entrega

- El informe debe subirse al Campus Virtual en formato PDF con el nombre **Ciencia_Datos_TP3_Grupo#**.pdf (donde # es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. La extensión máxima es de 10 páginas **contando el apéndice** y se espera una redacción clara y precisa.
- Se debe publicar en el repositorio de GitHub de cada grupo el código con los comandos utilizados, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Ciencia_Datos_TP3_Grupo#**.
- **Cualquier detección de copia o plagio será sancionada.**

El objetivo de este trabajo práctico es intentar predecir si una persona es pobre o no utilizando distintas variables de características individuales y los distintos clasificadores vistos en clase. Recuerden que en los trabajos prácticos anteriores crearon dos bases de datos distintas: `respondieron`, que tiene datos de personas que sí respondieron su ingreso (ITF) y `norespondieron`, que tienen aquellas personas que no declaran su ingreso.

A. Enfoque de validación

Utilicen la base `respondieron`. Para cada año, dividan las observaciones en una base de prueba (test) y una de entrenamiento (train) utilizando el comando `train_test_split`. La base de entrenamiento debe comprender el 70% de los datos, y la semilla a utilizar (*random state instance*) debe ser 444. Establezca a pobre como su variable dependiente en la base de entrenamiento (vector y). El resto de las variables seleccionadas serán las variables independientes (matriz X). Recuerden agregar la columna de unos (1) para el intercepto. *Aclaración: no incluir la variable ingreso en X para predecir la pobreza porque cuando vayamos a la base de norespondieron no vamos a tener esa información.*

1. Cree una tabla de diferencia de medias entre la base de entrenamiento y la de testeo de las características seleccionadas en su matriz X. Para la matriz de las X seleccione variables que hayan limpiado en los TPs anteriores y justifique su inclusión para predecir la pobreza. Comente la tabla de la diferencia de medias de sus variables entre entrenamiento y testeo. ¿Hay diferencias significativas entre las medias del entrenamiento y testeo?
2. Separen la base `respondieron` en dos: `respondieron_2005` y `respondieron_2025`. Idem con la base `norespondieron`.

B. Modelo de Regresión Logística

3. Estimación y Efectos Marginales: Estimen una **Regresión Logística** usando `X_train`. Exporten una tabla con: (i) los coeficientes estimados para cada variable, (ii) los errores estándar y (iii) los odd-ratios. Interpreten los resultados de la tabla. *Hint*: en la clase magistral 6 hay una ilustración de la tabla).
4. Visualización: Grafiquen la $\hat{P}(Y = 1|X)$ (en el eje vertical) y alguna característica **numérica** (en el eje horizontal). Comente dicho gráfico y la variable seleccionada para ilustrar la probabilidad de ser pobre según la característica seleccionada. (*Hint*: en la clase magistral 6 hay una ilustración de este estilo).

C. Método de Vecinos Cercanos (KNN)

5. Estimación: Clasifiquen a las observaciones como “pobre”/“no pobre” en su región con Vecinos Cercanos (**KNN**) usando $K=\{1,5,10\}$ para su matriz X_{train} . Expliquen en no más de 2-3 oraciones como la elección de K se relaciona con el trade-off sesgo varianza.
6. Visualización: Grafiquen dos características numéricas en su matriz X_{train} y visualicen las clases predichas por KNN usando con $K=\{1,5,10\}$ con su frontera por clase “pobre”/“no pobre”. (*Hint*: revisar Tutorial 8)
7. Para obtener el K óptimo usando Cross-Validation, dividiendo la base de `respondieron_2025` en 5 partes. Muestren cómo eligen el óptimo a través del gráfico visto en la tutorial sobre Accuracy en cada K . Llamenle a este modelo **KNN con K-CV**.

D. Desempeño de modelos, elección y predicción afuera de la muestra

8. Comparen el desempeño de predicción de pobreza en la base de *testeo* del modelo **Logit y KNN con K-CV**. Muestren la matriz de confusión (con umbral $p>0.5$), la curva ROC de ambos modelos, y dos métricas más vista en clase e interprete los resultados.
9. Suponga que el Ministerio de Capital Humano esta interesado en identificar a grupos vulnerables para dirigir los recursos de un programa de alimentos. Discutan cuál modelo de clasificación es “mejor” para predecir pobres y asignar dichos recursos escasos. (*Hint*: recuerden que en la clase magistral discutimos el trade-off de minimizar error tipo I o II)
10. Con el método que seleccionaron, predigan qué personas son pobres dentro de la base `norespondieron` para 2025. ¿Qué proporción de las personas que no respondieron pudieron identificar como pobres?